Projet ML : Prédiction multi-classe pour le chant d'oiseaux

De Michiel Gildas

Introduction

Le but du projet est d'identifier des espèces d'oiseaux à partir d'enregistrement audio. Contrairement à un problème de classification classique, ce projet constitue un problème d'apprentissage multi-classe. En effet, différentes espèces d'oiseau peuvent être présentent dans un seul et même fichier audio. De plus, ces enregistrements sonores ont été pris dans l'environnement naturel des oiseaux ce qui peut apporter du bruit dans les données. En effet, certaines particularités du problème rendent la prédiction bien plus difficile. Par exemple, le bruit environnemental comme le vent, ou bien la présence d'autres animaux, peut fausser les estimations. Aussi, les conditions d'enregistrement peuvent grandement affecter le signal sonore perçu par le modèle. De plus, le jeu de données présente un fort déséquilibre entre les classes, certaines espèces étant largement sous-représentées avec seulement 1 ou 2 exemples.

L'objectif de ce projet, est de concevoir un système de classification basé uniquement sur des méthodes d'apprentissage classiques. En effet, les réseaux de neurones sont explicitement exclus. Ainsi, les objectifs sont la mise en œuvre d'un pipeline qui permet de pré-traiter des signaux audio, l'extraction des caractéristiques des fichiers audio avec le feature engineering, l'entraînement de modèles supervisés, ainsi que l'évaluation de leurs performances.

Le but de cette analyse expérimentale est de tester différentes approches qui pourraient améliorer les performances de nos modèles. Plusieurs stratégies d'extraction de caractéristiques ont été explorées. Les coefficients cepstraux en fréquences de Mel (MFCC) ont été utilisé notamment pour leur rapidité et leur efficacité. Les dérivées temporelles ont aussi été utilisées, ainsi que des techniques de segmentation audio. Par ailleurs, on a procédé à une analyse de la redondance et de la corrélation entre les variables afin d'essayer de réduire le bruit lié aux features.

Pour finir, l'objectif de ce travail est surtout de comprendre l'impact des choix effectués. L'accent est mis sur l'interprétation des modèles, l'analyse des erreurs et la justification des décisions prises tout au long du projet. Ainsi, on ne se concentrera pas sur l'obtention des meilleurs résultats possibles.

Description du jeu de données

Le dataset utilisé dans ce projet provient du concours BirdCLEF 2026. Il propose une collection d'enregistrements audio d'oiseaux issus d'environnements naturels. Ces données ont été collectées dans des conditions réelles, ce qui implique la présence de nombreux bruits de fond (vent, eau, insectes). Ceci a pour conséquence de rendre la tâche de classification beaucoup plus complexe.

Le dataset principal est constitué de 35549 fichiers audio, chacun associé à une espèce d'oiseau distinctes. Ces fichiers sont accompagnés d'un label indiquant l'espèce présente dans l'enregistrement. La durée des fichiers peut varier ce qui nécessite une étape de prétraitement.

En complément, le dataset inclut des fichiers qui correspondent à des enregistrements environnementaux. Ces fichiers sont plus longs et contiennent plusieurs espèces pouvant être présentes simultanément. Ils sont annotés avec des intervalles de temps indiquant les périodes d'activité de différentes espèces.

Un des principaux défis de ce jeu de données réside dans le déséquilibre des classes. Une analyse du dataset met en évidence plusieurs caractéristiques importantes. Le dataset contient 206 espèces d'oiseaux distinctes. De plus, la distribution du nombre d'exemples par espèce est fortement déséquilibrée. Certaines espèces sont très peu représentées. En effet, 25 espèces (environ 12 %) possèdent moins de 10 exemples. En moyenne, chaque espèce dispose d'environ 173 enregistrements, avec un écart-type élevé de 155. Ceci montre une forte variabilité entre les classes. Aussi, le fait que la médiane de 125 est inférieure à la moyenne, confirme que la distribution est dominée par les classes majoritaires.

En moyenne dans les données *soundscapes*, un segment contient environ 4,2 espèces, avec un maximum pouvant atteindre 10 espèces. Cette caractéristique illustre le caractère multi-classe du problème.

Ces observations confirment que le dataset présente à la fois un fort déséquilibre des classes et une complexité multi-classe élevée. Ces éléments vont grandement impacter les performances des modèles. De nombreux défis tel que la qualité de l'audio, les bruits ambiants, ainsi que le déséquilibre des classes, compliquent la prédiction de classe. En effet en condition réelle, ces problèmes peuvent survenir d'où l'intérêt de trouver des méthodes de classification audio pour améliorer les performances.

Prétraitement des données

Avant l'entraînement des modèles de classification, une étape de prétraitement a été appliquée afin d'obtenir une représentation numérique exploitable des enregistrements audio. L'objectif était de standardiser les fichiers, d'extraire des caractéristiques pertinentes et de construire un jeu de données adapté à l'apprentissage supervisé.

Dans un premier temps, l'ensemble des données a été chargé à partir du fichier train.csv, qui associe à chaque enregistrement audio une espèce d'oiseau. Chaque fichier audio a été chargé à l'aide de la bibliothèque SoundFile. Lorsque l'enregistrement comportait plusieurs canaux, ceux-ci ont été convertis en un signal mono par moyennage des canaux. Cette étape permet d'obtenir une représentation unique du signal tout en réduisant la quantité de données à traiter.

Afin d'assurer une cohérence entre tous les enregistrements, les signaux ont été rééchantillonnés à une fréquence de 32 kHz. Cette fréquence correspond à celle recommandée pour le challenge BirdCLEF. De plus, elle garantit que toutes les caractéristiques sont extraites à partir d'un espace de même dimension pour chaque fichier.

Pour limiter les temps de calcul et homogénéiser la durée des exemples, seules les cinq premières secondes de chaque enregistrement ont été conservées. Les fichiers dont la durée était inférieure à cinq secondes ont été ignorés afin d'éviter la création de vecteurs de caractéristiques incomplets. Les éventuelles erreurs de lecture ou fichiers corrompus ont également été automatiquement exclus du jeu de données.

Enfin, les labels ont été converties vers un format exploitable. En effet, les labels textuels ont été transformés en représentations binaires multi-label à l'aide de la classe MultiLabelBinarizer. Cette étape est indispensable puisque plusieurs espèces peuvent être présentes simultanément dans un même enregistrement. Chaque espèce est alors représentée par une colonne binaire indiquant sa présence ou son absence dans l'exemple considéré.

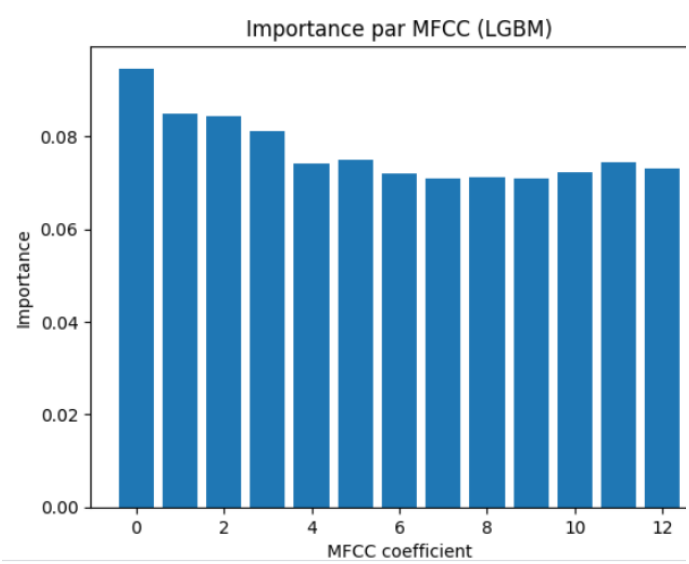
Feature Engineering

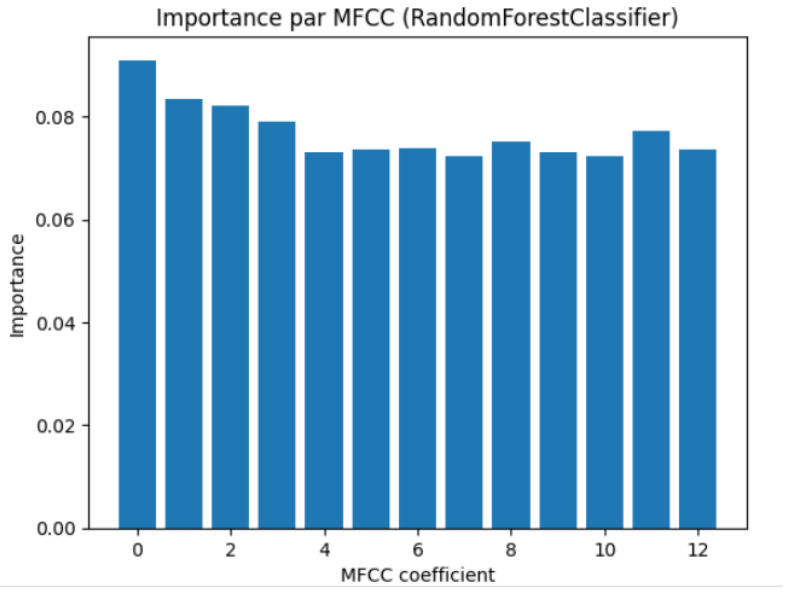
L’étape de feature engineering constitue un élément central de ce projet. En effet, les modèles utilisés ne sont pas capables d’extraire automatiquement des représentations pertinentes à partir du signal sonore brut. Il est donc nécessaire de transformer les enregistrements audio dans des formats exploitables par nos modèles.

Représentation MFCC

Dans un premier temps, les coefficients cepstraux en fréquences de Mel (MFCC) ont été utilisés comme représentation principale du signal audio. Les MFCC sont utilisés en traitement de la parole et de l’audio, car ils permettent de capturer la structure du signal sonore de manière compacte.

Pour chaque fichier audio, les 13 premiers coefficients MFCC ont été extraits. Nous avons utilisé des statistiques descriptives afin de résumer l’audio. Les statistiques utilisées sont la moyenne, l’écart-type, le minimum et le maximum. Cette approche permet de résumer l’évolution temporelle du signal sous forme d’un vecteur numérique qui pourra être exploité par les modèles de machine learning.





On peut voir que l’importance des MFCC est globalement la même pour les deux modèles. Une observation importante est que le coefficient MFCC 0, lié à l’énergie globale du signal, se distingue nettement des autres features. Il constitue une information particulièrement utile pour détecter la présence ou l’absence de signal sonore. Son importance vient probablement du fait que le modèle commence à faire des prédictions lorsqu’un chant d’oiseau est détecté.

Dérivé delta et delta^2

Afin d'apporter des informations temporelles plus précise, les dérivées delta des MFCC ont été introduites. Ces dérivées permettent de capturer les variations du signal au cours du temps, ce qui est particulièrement pertinent dans le cas des chants d'oiseaux. En effet, le chant d'un oiseau est souvent caractérisé par des motifs sonores différents entre espèces. Donc, ces features auront pour but de mieux dissocier des chants d'oiseau similaires.

En regardant l'analyse de l'importance des coefficients MFCC, de la dérivé delta et de la dérivé delta2, on peut voir que 40 % de l'importance des features est attribué à la MFCC, tandis que les autres sont à 30 % d'importance. Ceci montre que les MFCC restent dominants, mais que les delta et delta2 contribuent également à la prédiction des modèles. Cela confirme l'intérêt d'intégrer des informations sur les variations temporelles des chants d'oiseaux.

Descripteur spectraux (ZCR + CENTROID + ROLLOF)

En complément des coefficients MFCC, trois descripteurs spectraux classiques ont été étudiés : le Zero Crossing Rate (ZCR), le Spectral Centroid et le Spectral Rolloff. L'objectif était d'évaluer si ces caractéristiques pouvaient apporter des informations utiles pour la reconnaissance des espèces d'oiseaux.

Le Zero Crossing Rate (ZCR) mesure combien de fois le signal sonore change de signe dans un intervalle donné. Cette mesure permet par exemple de calculer la périodicité ou bien la présence de composantes haute fréquence.

Le Spectral Centroid correspond au centre de gravité du spectre fréquentiel. Il fournit une estimation de la fréquence moyenne du signal et permet ainsi de différencier les sons graves des sons aigus.

Le Spectral Rolloff représente la fréquence en dessous de laquelle se trouve une grande partie de l'énergie du signal. Cette mesure renseigne sur l'étendue fréquentielle d'un signal audio. Deux chants pouvant présenter un centroid similaire peuvent néanmoins posséder des rolloff différents si l'un contient davantage de composantes de haute fréquence.

Ces trois descripteurs apportent donc des informations complémentaires aux MFCC. Alors que les MFCC décrivent la forme du spectre, le ZCR caractérise les variations et le niveau de bruit du signal, tandis que le centroid et le rolloff résument sa concentration fréquentielle.

Famille de features	Importance
MFCC	0.848
ZCR	0.055
Spectral Centroid	0.043
Spectral Rolloff	0.053

Ces résultats montrent que les coefficients MFCC concentrent près de 85 % de l'importance totale du modèle. Ceci confirme leur rôle central dans la reconnaissance des espèces. Les descripteurs

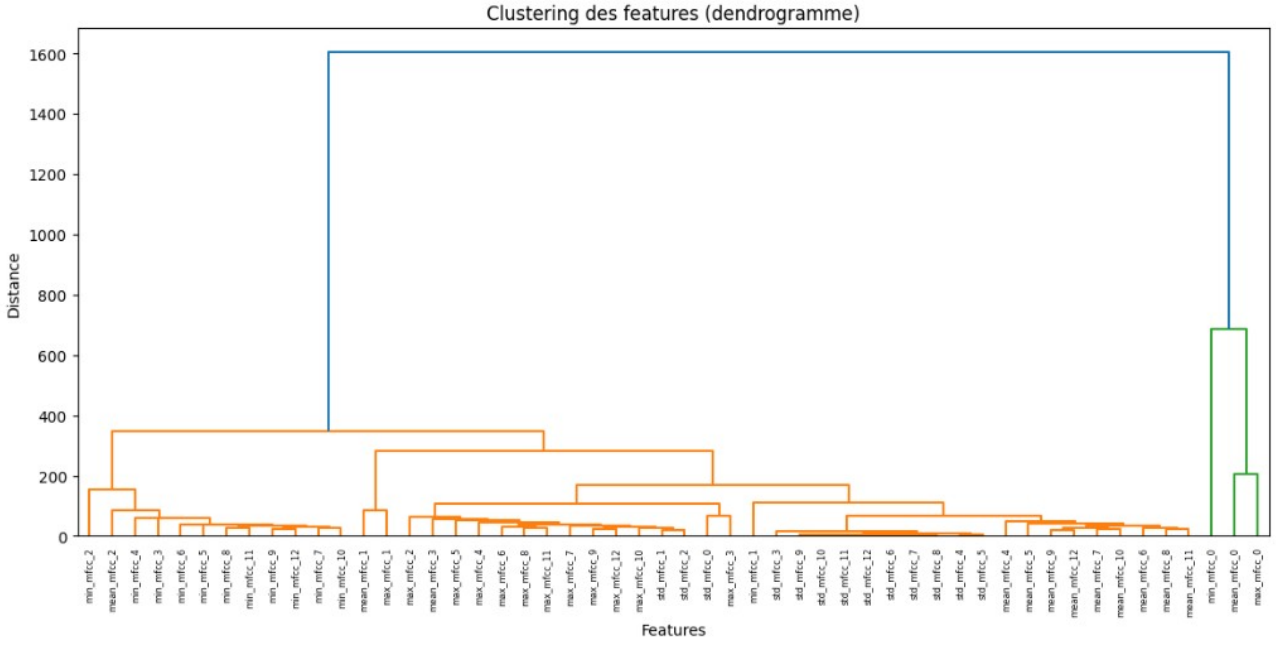
spectraux contribuent néanmoins à hauteur d'environ 15 % de l'importance totale. Leur influence est donc loin d'être négligeable. Cette répartition suggère que ces descripteurs n'apportent pas suffisamment d'information pour remplacer les MFCC. Cependant, ils fournissent des informations complémentaires permettant aux modèles de mieux distinguer certaines espèces.

Segmentation temporelle

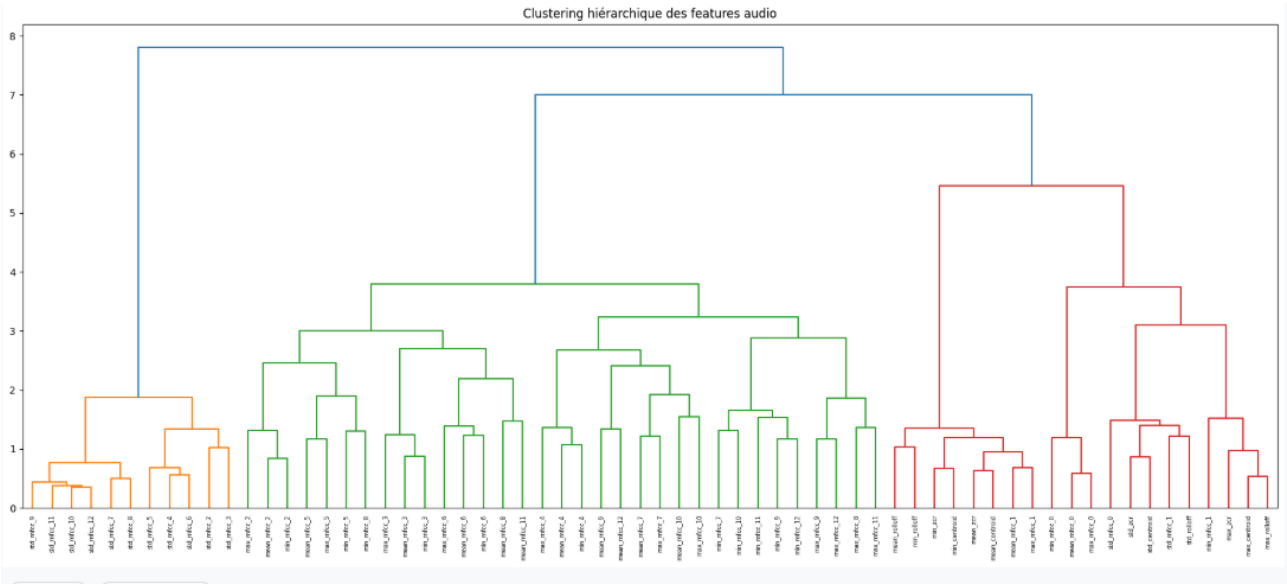
Par ailleurs, différentes stratégies de segmentation des signaux audio ont été explorées. Une approche consistant à découper les enregistrements en sous-segments indépendants a été testée. Une autre approche de segmentation a également été utilisé. Cette alternative est basée sur des fenêtres glissantes (sliding window). L'objectif est de mieux capturer la structure temporelle du signal sonore sans trop le fragmenter.

Tentatives de réduction de dimension (PCA)

Une analyse des features a été réalisée afin d'identifier d'éventuelles redondances. Une matrice de corrélation ainsi qu'un clustering hiérarchique des features ont été utilisés pour visualiser les relations entre variables. Les matrices de corrélation des features n'ont pas révélé beaucoup de corrélation entre les features. En effet, dans tous les tests effectués, il n'existe aucun couple de features corrélé à plus de 90 %. Ceci suggère que les features sont suffisamment distincts, et n'apportent pas d'informations redondantes.



Cependant, le clustering hiérarchique nous confirme certaines informations. On peut voir sur ce graphique que 3 des 4 features du coefficient 0 de la MFCC sont dans le même cluster, tandis que les autres features sont toutes dans un autre cluster. Ceci montre encore une fois la différence du coefficient 0 de la MFCC par rapport aux autres coefficients. Pour ce qui est des features associées aux dérivées delta et à la séparation temporelle, les résultats restent les même.



Cependant, on peut voir une légère différence pour ce qui est de l'ajout des descripteurs spectraux. En effet, un nouveau cluster apparaît. Le premier cluster est constitué des écart-types des coefficients MFCC supérieurs à 2. Ceci indique qu'ils permettent de capturer la variabilité des chants d'oiseau, et donc de mieux discerner des signaux sonores similaires. Le deuxième cluster est composé des min, max, et moyenne des MFCC supérieurs à 2. Ces features permettent de représenter la structure du signal sonore dans sa globalité. Le troisième cluster contient les statistiques des MFCC 0 et 1, ainsi que le ZCR, le Centroid, et le Rolloff. Le clustering révèle que ces trois nouvelles familles de variables sont fortement associées aux MFCC 0 et 1. Elles enrichissent légèrement la représentation, mais restent partiellement redondantes avec les premiers coefficients MFCC.

Par la suite, une réduction de dimension par PCA conservant 90 % de la variance sera appliquée afin de limiter les redondances et le bruit des variables.

Analyse expérimentale

Cette section présente les différentes expérimentations menées afin d'évaluer l'impact des choix de représentation et de modélisation sur les performances du système. L'évaluation est réalisée à l'aide du F1-score. Chaque expérience a été répétée avec plusieurs graines aléatoires afin d'évaluer la stabilité des résultats.

Choix des modèles

Dans un premier temps, deux modèles ont été comparés. Un Random Forest et un modèle basé sur LightGBM. Avec une représentation initiale utilisant 13 coefficients MFCC, les résultats obtenus sont les suivants. Un score d'environ 0.076 pour le LightGBM, et d'environ 0.012 pour le modèle RandomForest.

Cette différence significative montre que LightGBM est nettement plus adapté à ce problème. Le RandomForest est moins performant. Cependant, les résultats sont loin d'être satisfaisant à cause du déséquilibre entre les classes. C'est pour ceci qu'on a décidé d'utiliser deux modèles adapté au problème. Un LightGBM avec *class_weight="balanced"* et un BalancedRandomForestClassifier. Ces modèles ont pour particularité de réduire le déséquilibrage grâce à une pondération sur les classes pour le LightGBM et un sous-échantillonnage des exemples majoritaires pour le BalancedRandomForestClassifier.

Impact du rééquilibrage des classes

L'introduction d'un mécanisme de rééquilibrage constitue l'amélioration la plus significative observée au cours du projet. LightGBM atteint un F1-score d'environ 0.144, contre des valeurs inférieures à 0.08 dans les expériences initiales sans pondération. BalancedRandomForest obtient quant à lui un score d'environ 0.062.

Cette amélioration s'explique par la forte présence de classes rares dans le dataset. Sans rééquilibrage, les modèles privilégient naturellement les espèces les plus fréquentes et négligent les classes minoritaires. La pondération des classes permet d'augmenter l'importance des exemples rares durant l'apprentissage, ce qui améliore significativement le F1-score.

Dérivée delta et delta^2

L'ajout des delta MFCC constitue l'amélioration la plus efficace après le rééquilibrage des classes. Les performances de LightGBM sont d'environ 0.161, tandis que celles du BalancedRandomForest atteignent environ 0.071.

Les delta MFCC décrivent les variations temporelles des coefficients MFCC entre deux instants successifs. Contrairement aux MFCC classiques qui représentent principalement la structure fréquentielle moyenne du signal, les delta MFCC capturent l'évolution du chant au cours du temps. Cette information est particulièrement pertinente pour les oiseaux, dont les chants sont caractérisés par des variations rapides de fréquence et d'intensité. Ainsi, ces résultats confirment que la prise en compte des variations temporelles apportent une information complémentaire utile pour discerner des espèces similaires.

Descripteurs spectraux (ZCR + CENTROID + ROLLOF)

Le modèle LightGBM obtient des résultats relativement stables avec une moyenne proche de 0.151, tandis que le BalancedRandomForest atteint environ 0.064 de score.

En comparaison des expériences réalisées uniquement avec les MFCC, les performances de LightGBM augmentent légèrement. L'ajout du ZCR, du centroid et du rolloff ne provoque donc pas de gain majeur. Cette observation est cohérente avec l'analyse des importances qui nous dit que les coefficients MFCC capturent déjà l'essentiel de l'information.

Cependant, l'absence d'amélioration importante ne signifie pas que ces variables sont inutiles. Leur contribution cumulée représente près de 15 % de l'importance du modèle. Ce résultat indique qu'elles participent effectivement aux décisions de classification. Leur faible impact sur le score global peut s'expliquer par le fait que les informations qu'elles apportent sont en partie redondantes avec celles déjà contenues dans les MFCC.

Segmentation temporelle

Deux approches ont été explorées afin d’intégrer davantage d’information temporelle.

Découpage en deux segments

La première méthode consiste à découper les cinq premières secondes de l’enregistrement en deux parties indépendantes et à concaténer les features extraites sur chaque segment. Cette stratégie a conduit à une baisse des performances. Le LightGBM obtient un score d’environ 0.136, tandis que le BalancedRandomForest obtient un score d’environ 0.061

La baisse de performance est très probablement due à la perte de contexte temporel. Les chants d’oiseaux peuvent s’étendre sur plusieurs secondes et présenter des motifs sonores continus. Le découpage fragmente ces motifs et réduit la stabilité des statistiques calculées sur chaque segment.

Fenêtres coulissantes

Une seconde approche basée sur des fenêtres glissantes a ensuite été testée. Les performances restent proches de celles obtenues avec les MFCC seuls. Le LightGBM obtient en moyenne 0.143, tandis que le BalancedRandomForest obtient environ 0.059.

Cette méthode conserve mieux la temporalité que le découpage brut. Cependant, son ajout n’apporte pas d’amélioration. Une hypothèse est que les statistiques globales calculées sur les MFCC capturent déjà une grande partie de l’information utile présente dans les cinq premières secondes du signal.

Effet de l’analyse en composantes principales (PCA)

Une réduction de dimension par PCA conservant 90 % de la variance a été appliquée afin de limiter les redondances et le bruit des variables.

Dans le cas des MFCC seuls, les résultats baissent légèrement. LightGBM obtient environ 0.14 de score, tandis que BalancedRandomForest obtient environ 0.63. Cette baisse s’explique par le fait que les coefficients restent utiles pour différentier des chants d’oiseaux similaires et aider à la reconnaissance des chants d’oiseau rares. La réduction de dimension avec 90 % de la variance a fait passer le nombre de features de 52 à 15.

Cependant, lorsque les delta MFCC sont ajoutés, le PCA entraîne une baisse notable des performances pour le LightGBM. En effet, celui-ci obtient environ 0.132. Pourtant, le BalancedRandomForest obtient une augmentation de performance avec en moyenne 0.845. La réduction de dimension avec 90 % de la variance a fait passer le nombre de features de 156 à 50.

L’application supplémentaire d’un PCA après les fenêtres glissantes entraîne une nouvelle baisse des performances pour les deux modèles. Environ 0.116 pour le LightGBM et environ 0.054 pour le BalancedRandomForest. Cela suggère une nouvelle fois que certaines composantes de faible variance restent informatives pour la tâche de classification.

L'application d'un PCA conservant 90 % de la variance a conduit à une amélioration des performances du BalancedRandomForestClassifier, et à une diminution de celles de LightGBM. Cette différence peut s'expliquer par la nature des deux algorithmes. La réduction de dimension supprime une partie des corrélations et du bruit présents dans les variables MFCC. Ceci a pour effet de faciliter la construction d'arbres pour le BalancedRandomForest. En effet, si deux variables sont fortement corrélé alors leur split n’apporte pas beaucoup d’informations supplémentaires. À l'inverse, LightGBM corrige les erreurs des classifiers de manière séquentielle. Ainsi, le modèle est résistant au bruit. Certaines composantes supprimées par le PCA, semblent contenir des informations discriminantes pour la classification. Leur suppression dégrade donc les performances du modèle de boosting. En cherchant uniquement à préserver la variance globale, le PCA peut éliminer des informations pertinentes pour distinguer certaines espèces rares. Cette observation illustre l’idée qu’une forte variance n’implique pas nécessairement une forte capacité de prédiction.

Augmentation et diminution des MFCC

Une tentative de simplification consistant à ne conserver que les coefficients MFCC de 0 à 4 a été testée. Cette approche a entraîné une forte dégradation des performances pour les deux modèles. Cette baisse indique que les coefficients plus élevés contiennent également de l’information utile, contrairement à ce que pouvait suggérer l’analyse de corrélation et des clusters.

Enfin, une augmentation du nombre de coefficients MFCC (passage de 13 à 30) a été testée. Cette modification a permis d’améliorer les performances environ 0.153 pour le LightGBM, et environ 0.77 pour le BalancedRandomForestClassifier. Ces résultats qui indiquent que l’ajout de coefficients supplémentaires apporte des informations utiles dans ce contexte.

Synthèse des résultats

Sur l’ensemble des expériences, LightGBM obtient systématiquement les meilleurs résultats. Alors que les performances du BalancedRandomForest restent généralement comprises entre 0.05 et 0.08, celles de LightGBM se situent entre 0.12 et 0.17.

Cette différence peut s’expliquer par la nature des deux algorithmes. Le BalancedRandomForest repose sur une stratégie de bagging. Chaque arbre est entraîné indépendamment sur un sous-échantillon équilibré. Cette approche améliore la prise en compte des classes rares, mais a aussi pour effet de pénaliser les classes majoritaires.

À l’inverse, LightGBM utilise une stratégie de gradient boosting où chaque arbre cherche à corriger les erreurs des précédents. Cette approche est particulièrement efficace lorsque les features discriminantes sont peu nombreuses.

Les expériences réalisées permettent d’obtenir plusieurs résultats :

- Le rééquilibrage des classes est indispensable dans ce contexte fortement déséquilibré.
- LightGBM est systématiquement plus performant que BalancedRandomForest.
- Les delta MFCC apportent un gain significatif en capturant les varaitions temporelle du chants des oiseaux.
- Le PCA n’améliore pas les performances du LightGBM et peut même dégrader les résultats. En effet, le modèle peut perdre des informations discriminantes si elles sont réparties dans des composantes de faible variance. À l’opposé, le BalancedRandomForest voit ses performances améliorer. Cette augmentation est probablement due à une réduction du bruit dans les données.
- Les stratégies de segmentation temporelle testées n’apportent pas d’amélioration par rapport à l’utilisation directe des MFCC seuls.

Le meilleur résultat obtenu au cours de cette étude correspond à l’utilisation de LightGBM pondéré combiné aux MFCC et aux delta MFCC, avec un F1-score d’environ 0.168.

Conclusion

Ce projet avait pour objectif de concevoir un système de classification audio capable d'identifier des espèces d'oiseaux à partir d'enregistrements sonores. Les différentes expérimentations réalisées ont permis d'obtenir divers résultats.

Tout d'abord, le choix des représentations audio joue un rôle central dans la performance des modèles. Les coefficients MFCC, et leurs dérivées delta et delta^2 donne les meilleurs gains de performances. Ainsi, ils constituent une bonne base pour représenter le signal audio.

Ensuite, les tests réalisés ont montré que certaines simplifications des features, notamment la réduction de dimension ou la suppression de coefficients MFCC, peuvent entraîner une dégradation des performances. Cette dégradation est liée à la perte d'informations discriminantes pour les classes rares dans les composantes de faibles variances. Cependant, si le PCA est couplé avec une augmentation du nombre de coefficients MFCC, alors les résultats s'améliorent nettement. En effet, la combinaison de ces deux méthodes apporte les deuxièmes meilleurs résultats derrière l'ajout des dérivées delta.

De plus, l'ajout d'informations temporelles via des méthodes de segmentation ou de fenêtres glissantes ne permet pas d'augmenter les performances. Ces méthodes avaient pour objectif de mieux capturer les variations temporelles des signaux sonores. Cependant, elles n'ont fait qu'ajouter du bruit.

Pour finir, les descripteurs spectraux ZCR, centroid, et rollof améliore légèrement les performances. Ces features permettent de représenter la concentration et les variations du signal. L'analyse par clusters hiérarchiques montre que ces features sont plutôt similaires aux coefficients 0 et 1 du MFCC. Elles permettent néanmoins de discriminer des chants d'oiseaux similaires.

Du point de vue des modèles, LightGBM s'est révélé nettement plus performant que BalancedRandomForest. Cette différence s'explique par sa capacité à mieux exploiter les signaux faibles. De plus, le LightGBM permet de gérer des données déséquilibrées avec l'hyperparamètre class_weight='balanced', qui permet d'ajouter une pondération aux classes. Les faibles performances de BalancedRandomForest s'expliquent par ses stratégies de sous-échantillonnages des données et de bagging. En effet, l'ensemble de ces stratégies ont pour effet de priorisé les classes rares au détriment des classes majoritaires.

Enfin, ce travail souligne les difficultés de ce problème multi-classe. En effet, le dataset est caractérisé par un fort déséquilibre des classes. De plus, la présence de plusieurs oiseaux dans le même segment audio complexifie le problème. Les résultats mettent en évidence les limites des méthodes classiques de classification face à des données audio réelles. Ainsi, les performances globales dépendent autant de la qualité des features que du choix du modèle et de la stratégie de décision.